

AgentForge-Lite 产品手册

企业级 Agent 运行时平台 · 技术规格说明书

产品名称：AgentForge-Lite
适用版本：v4.1
文档编号：XH-PM-2026-0417
发布日期：2026-10-01 密级：内部公开
维护部门：平台研发部

1. 产品概述

AgentForge-Lite 是一套面向企业内网部署的 Agent 运行时平台，把「文档知识库 — 检索增强问答 — 工具调用型 Agent — 效果评测」四条链路收进同一个可自托管进程。

它解决的问题是：企业内部往往已经有大量制度、手册、FAQ 文档，但员工检索靠关键词翻页、问答靠人工转述。本产品将这批文档统一入库、切分、向量化，使员工可以用自然语言提问并获得带出处引用的回答；回答无法覆盖的问题，可由 Agent 调用外部系统工具继续求解。

1.1 核心能力

- 文档知识库**：支持 PDF / DOCX / Markdown / TXT 四种格式入库，自动解析、切分与向量化。
- 混合检索问答**：向量检索与关键词检索双路并行，融合后可选重排，回答附带原文引用与页码定位。
- 工具调用 Agent**：基于状态图的推理—行动循环，可装载本地工具与外部 MCP 协议工具。
- 会话与记忆**：多会话管理，长对话自动摘要压缩，避免上下文溢出。
- 评测与可观测**：内置评测集与自动评分，全链路埋点可回流至链路追踪平台。

1.2 部署形态

产品以 Docker Compose 形式交付，一条命令拉起 **数据库 / 缓存 / 应用服务 / 前端站点** 四个容器，无需外部托管依赖即可离线运行；大模型与嵌入模型均可指向本地推理服务。

2. 运行环境要求

项目	最低要求	推荐配置
操作系统	Linux x86_64 / macOS (Apple Silicon)	Linux x86_64
容器运行时	Docker Engine 24.0 + Compose v2	Docker Engine 27.0
内存	4 GB	8 GB 及以上
磁盘	5 GB (含模型与镜像)	20 GB
数据库	PostgreSQL 16 (需向量扩展 pgvector)	同左
缓存	Redis 7	同左

首次启动说明：本地嵌入模型与重排模型合计约 **1.1 GB**，不计入镜像体积，以挂载方式提供。首次运行需下载词嵌入模型（约 23 MB，视模型而定）；若启用外部工具网关，还需预拉取其命令行包。**建议在正式演示或使用前先执行一次预热脚本**，否则首次提问会因现场下载而明显卡顿。

3. 文档与知识库规格

3.1 支持的文件格式

扩展名	类型	解析行为
<code>.pdf</code>	PDF 文档	按页解析，每页保留页码引用；扫描件（无文本层）无法提取会明确报错
<code>.docx</code>	Word 文档	按段落解析，页码引用为空
<code>.md</code>	Markdown	整篇作为一段解析，页码引用为空
<code>.txt</code>	纯文本	整篇作为一段解析，页码引用为空

单文件大小上限为 20 MB。超出上限或格式不在白名单内的文件，在请求阶段即被拒绝，不会产生无效记录。

3.2 切分规格

- 切片长度：300 字符（每片的目标字符数）
- 相邻重叠：50 字符（防止把一句话从中间切断）
- 切片步长 = 切片长度 - 重叠 = 250 字符

3.3 入库流程

上传接口返回 202 Accepted（已受理）而非 200，随后在后台完成解析、切分与向量化。文档状态依次为 processing → ready（成功）或 failed（解析失败，如损坏的 PDF）。调用方可轮询文档列表接口跟踪状态。

4. 检索与问答规格

4.1 两路召回

检索路径	原理	适用场景
向量检索	查询与切片分别编码为向量，按余弦相似度排序（pgvector）	语义相近、用词不同
关键词检索	基于 PostgreSQL 全文索引（tsvector + GIN）打分	专有名词、编号、缩写

4.2 融合与重排

- 融合方式：RRF（倒数排名融合），融合常数 $k = 60$ ，两路各取前 20 条候选。
- 重排（可选）：使用交叉编码器模型对候选逐一打分后重新排序，精度更高但耗时更长。
- 返回条数：默认 $\text{top_k} = 5$ 。

4.3 三种检索模式

模式	链路
<code>pure_vector</code>	仅向量检索

hybrid	向量 + 关键词，RRF 融合
hybrid_rerank (默认)	向量 + 关键词 → RRF 融合 → 交叉编码器重排

4.4 模型规格

用途	模型	规格
词嵌入 (向量化)	BAAI/bge-small-zh-v1.5	中文，512 维，本地 ONNX 推理
重排	BAAI/bge-reranker-base	交叉编码器，本地 ONNX 推理，超时 3 秒
对话生成	可配置 (云端 API 或本地服务)	与嵌入模型解耦配置

注意：向量维度与嵌入模型强绑定。更换嵌入模型时必须重建全部索引，否则相似度计算将失去意义。

5. Agent 与工具规格

5.1 推理—行动循环

Agent 基于状态图编排，单轮问答的循环为：**生成回答** → **若需要外部信息则发起工具调用** → **执行工具** → **带着结果再次生成**。循环设有最大轮次上限，超限后返回当前可得的最佳回答，不会无限重试。

5.2 工具来源

来源	说明
内置工具	随产品发布，如时间查询、知识库检索
外部 MCP 工具	经协议客户端动态挂载，工具名带来源前缀以区分同名冲突

5.3 降级策略

外部工具服务不可达时**不会阻断主流程**：连接失败的来源整体下线，Agent 自动降级为纯知识库问答。可通过工具列表接口确认当前已装载的工具及其来源。

6. 接口规格

接口	方法	用途
/api/health	GET	健康检查
/api/chat	POST	与 Agent 对话
/api/documents	POST / GET	上传文档 / 文档列表
/api/documents/{id}/preview	GET	文档详情与切片预览
/api/documents/{id}	DELETE	删除文档（级联删除切片）
/api/sessions	GET	会话列表与消息明细
/api/eval/cases /api/eval/runs	GET	评测集与评测运行结果
/api/tools	GET	当前已装载工具清单

所有接口统一挂在 /api 前缀下。生产部署时由前置 Web 服务同源转发，前端站点与接口服务无需跨域配置。

7. 版本历史

版本	日期	主要变更
v4.1	2026-10-01	容器化交付；评测与可观测链路完善；工具来源隔离
v4.0	2026-09-20	引入重排与评测体系；会话记忆升级为摘要压缩
v3.0	2026-09-10	混合检索上线（向量 + 关键词 + RRF）

v1.0	2026-08-28	首个可用版本：文档入库 + 向量检索 + 问答
------	------------	-------------------------